

UNIVERSITATEA DIN BUCUREȘTI

FACULTATEA DE MATEMATICĂ ȘI INFORMATICĂ



SPECIALIZAREA INFORMATICĂ

Lucrare de licență

MODELAREA TIMPILOR DE TASTARE LA NIVEL LEXICAL ȘI ANALIZA CORELAȚIEI ACESTORA CU METRICILE DE SURPRISAL GENERATE DE MODELELE DE TIP LLM

Absolvent

Militaru Ștefan-Octavian

Coordonator științific

Conf. dr. Nisioi Sergiu

București, iunie 2026

Rezumat

Proiectul prezentat în această lucrare de licență are ca scop implementarea unui predictor al timpilor de tastare pentru cuvinte. Se va prezenta analiza făcută asupra scorurilor de surprisal generate de LLM-uri și se va încerca corelarea acestor valori cu cele înregistrate de subiecții umani la tastarea acelorași propoziții. Pe lângă aceste scoruri de surprisal vor fi extrase și augmentate și alte caracteristici ale cuvintelor, menite să asigure performanța predictorului. Mai apoi, va fi detaliată realizarea unei interfețe web prin care un utilizator poate atât să interacționeze cu modelul predictor, cât și să vizualizeze o comparație dintre comportamentul său la redactarea propoziției și cel al modelului LLM BERT.

Abstract

The goal of the project presented in this thesis is the implementation of a predictor that models word typing times. The analysis of surprisal scores generated by LLM models on given sentences and the comparison between these and the times recorded by human subjects will be documented in detail. Additionally, many more word-specific features will be extracted from the dataset in order to boost the predictor's performance. The development of a web interface will also be presented, through which the user can interact with the predictor and view the comparison between their typing behaviour and the one recorded by the BERT LLM model.

Cuprins

1 Introducere **4**

2 Preliminarii **6**

3 Proiectul **8**

3.1 Metode 8

3.1.1 Setul de date 8

3.1.2 Modelul BERT 9

3.1.3 Tehnici de masking 9

3.1.4 Calcularea scorului de surprisal prin BERT 11

3.1.5 Extragerea caracteristicilor pentru predictor 13

3.1.6 Antrenarea modelelor de prezicere 15

3.1.7 Analiza performanței modelelor 17

3.1.8 Interfața web 18

3.2 Rezultate 19

3.2.1 Comparația surprisal cu timpii de tastare 19

3.2.2 Importanța caracteristicilor 20

4 Concluzii **21**

Bibliografie **22**

Capitolul 1

Introducere

Domeniul modelării limbajului prin intermediul modelelor de inteligență artificială a cunoscut, în perioada recentă, un progres masiv și accelerat, elevând performanța și proficiența acestora la un nivel aproape uman. Modelele de tip LLM (Large Language Model) au capabilități lingvistice avansate, construind fraze și paragrafe în moduri cât mai naturale și utilizând construcții lexicale complexe și cu sens lingvistic corect. Deși performanța acestora este deja apropiată de cea a oamenilor, există câteva aspecte pe care acestea nu le pot încă modela. Dintre acestea, prezintă interes problema construcției unei propoziții în mod natural, simulând modul în care oamenii acordă atenție variată pentru diferite părți lexicale.

Construcția naturală a unei fraze necesită simularea tuturor complexităților gândirii umane, fapt ce este, la momentul actual, imposibil de realizat de către un model de inteligență artificială. Ceea ce este însă posibil cu tehnologiile existente este axarea pe un anumit detaliu al construcției de fraze sau propoziții și replicarea acesteia cu ajutorul unui model. Reproducerea timpilor de scriere sau tastare generate de oameni este un exemplu de detaliu ce poate fi folosit pentru a „umaniza" producțiile lingvistice artificiale.

În această teză va fi încercată o astfel de reproducere, analizând similaritățile dintre procesul cognitiv uman (aproximat prin viteza de generare și tastare a cuvintelor) și mecanismul de generare propozițională al modelelor (reprezentat prin metrica de surprisal) și utilizând această analiză pentru construirea unei metode prin care programul poate simula tastarea unei propoziții de către un om. Rezultatul obținut ar putea fi mai apoi utilizat de un LLM pentru a augmenta proficiența sa în comunicarea într-un mod uman, sau aplicat în alte programe ce au nevoie de în-

registrarea vitezei de procesare a oamenilor, precum generarea de subtitrări pentru videoclipuri, conversații, prelegeri, etc.

Modul în care modelele moderne de producție lingvistică generează, construiesc și verifică corectitudinea propozițiilor create a reprezentat mereu o fascinație personală. Atât diferențele cât și similaritățile între modul de gândire uman și algoritmii de generare propozițională utilizați de LLM-uri dezvăluie direcția și amplitudinea progresului în domeniul procesării limbajului natural. Proiectul are ca țintă analiza particularităților acestor două metode de construcție propozițională și utilizarea rezultatelor pentru a construi modele mai capabile de a replica comportamentul uman în cadrul comunicării de la distanță.

Structura acestei lucrări va urmări prezentarea tuturor aspectelor necesare atât pentru analiza inițială a comportamentului LLM-urilor cât și pentru dezvoltarea modelului final. Prima parte a proiectului a urmărit extragerea scorurilor de surprisal generate de un model pe fiecare cuvânt al unei propoziții și analizarea corelației dintre acestea și dintre timpii de tastare întregistrați de oameni. În a doua parte au fost realizați toți pașii necesari pentru crearea unui model de prezicere a timpilor de tastare pe cuvinte: extragerea și augmentarea feature-urilor pentru cuvinte, antrenarea modelului pe setul de date ales și testarea acestuia pe propoziții noi. La final, va fi detaliată și crearea unei interfețe web prin care utilizatorul poate folosi predictorul construit și poate vizualiza comparația cu metricile generate de BERT la primul punct.

Capitolul 2

Preliminarii

Inspirația acestei teze a pornit de la lucrarea [1], unde este prezentată o analiză a pauzelor lexicale și a posibilelor motivații pentru lungimea acestora în producția lingvistică umană. Analiza de acest tip a pus bazele pentru ideea explorată în această lucrare, și anume procesul de gândire preliminar tastării unui cuvânt. Această teză extinde analiza prin utilizarea unui număr mai mare de caracteristici ale cuvântului, ci nu doar a pauzei antemergătoare acestuia. Și în sursa [2] este explorat modul de gândire uman în timpul producerii lingvistice, investigând similaritățile și diferențele dintre modurile în care copii de clasa a doua tastează și scriu de mână. Rezultatele sugerează că redactarea textelor la tastatură este realizată în bucăți mai mici, spre deosebire de procesul de scriere de mână în care se preferă partiționarea propozițiilor în burst-uri mai lungi.

O investigație asupra subiectului importanței cogniției în procesul de scriere este realizată în lucrarea [3], fiind de interes pentru scopul acestui proiect ultimul capitol în care este analizat impactul tehnologiilor software nou-apărute la acel moment asupra modului de redactare uman.

În studiul [4] este realizată o analiză mai amplă asupra timpilor de tastare înregistrați de populația generală. Acesta prezintă comportamentul și viteza la tastare colectate de la oameni de toate vârstele și cu orice nivel de experiență în utilizarea calculatoarelor. Conform sursei [5] există o legătură strânsă între proficiența la tastare și nivelul de cunoaștere al limbii respective. Aceste concluzii au determinat utilizarea datelor despre tastare în proiect întrucât sugerează faptul că acestea dezvăluie informații despre procesul cognitiv de construcție propozițională.

De asemenea, lucrarea [6] a sugerat o conexiune între cogniția umană și valorile de surprisal

generate de modele LLM. Această concluzie constituie una dintre cele mai însemnate motivații pentru investigația din prima parte a acestei teze și reprezintă o explicație bună a impactului și importanței acestor scoruri pentru domeniul procesării limbajului natural. O prezentare a corelației dintre această metrică și comportamentul uman la citire sau scriere este detaliată în sursa [7]. Sunt expuse rezultatele înregistrate și pe alte limbi decât engleza pentru a măsura relevanța surprisal-ului și în alte contexte.

Înregistrarea procesului de tastare a fost realizată cu informațiile prezentate în lucrarea [8], unde sunt prezentate tehnologii chiar mai performante decât ce s-a utilizat în acest proiect. Acestea se uită atât la textele tastate cât și la alte date ale subiectului, precum mișcarea ochilor pe pagină, pentru a detecta exact asupra cărei părți din text se concentrează acesta.

Rezultatul proiectului poate fi utilizat în cadrul mai multor domenii ale informaticii, fiind legat de mai multe probleme comune întâmpinate deseori de dezvoltatori. Primul uz major al acestuia ar putea fi simularea comportamentului conversațional uman prin modele de inteligență artificială, mai ales în timpul comunicării cu alte persoane. Spre exemplu, în cazul în care asistentul AI al unui anumit serviciu web nu este apreciat de clienți din cauza comportamentului robotic, introducerea unei astfel de augmentări la timpii de tastare poate face interacțiunea cu modelul mai naturală pentru utilizator. Rezultatul proiectului ar putea fi utilizat și de modelele de comunicare utilizate pentru oamenii în vârstă, pentru a îmbunătăți iluzia conversației cu o altă persoană. Bineînțeles, integrarea unei astfel de tehnologii fără a respecta politica de etică ar trebui interzisă, pentru a preveni eventuala inducere în eroare a utilizatorilor care nu ar afla că dialoghează cu un model de inteligență artificială.

Analiza timpilor de tastare ar putea fi utilizată și de serviciile care generează subtitrări automate pentru conținut transmis în direct. Problema corelării unui discurs sau a unei transmisii live cu traducerea reprezintă încă un exercițiu dificil în domeniu, însă o analiză de genul acesteia axată mai degrabă pe timpii de citire ar putea îmbunătăți experiența pentru telespectatori.

Capitolul 3

Proiectul

3.1 Metode

3.1.1 Setul de date

Calitatea oricărui proiect din domeniul Machine Learning depinde într-o proporție însemnată de dimensiunea și de relevanța setului de date de la care se pleacă. În cazul acestui proiect, atât etapa de comparare cât și etapa de implementare a modelului au necesitat utilizarea unui dataset care să măsoare timpii de scriere pe cuvinte din texte redactate de oameni. Datasetul [9] a oferit exact aceste informații, întrucât acesta conține peste 200 de perechi întrebare-răspuns la care se adaugă o analiză detaliată pentru tastarea fiecărui cuvânt dintre acestea.

Setul de date a fost generat cu ajutorul unor participanți voluntari care au răspuns la mai multe întrebări în limba engleză. Acestea au fost formulate în limbaj natural, de zi cu zi, iar răspunsurile oferite au fost sub forma unor propoziții de 20-30 de cuvinte. Subiectele întrebărilor au fost variate, dar au urmărit, în principal, descrierea unui anumit loc sau a unei anumite scene.

Mai multe date la nivel de cuvânt au fost înregistrate în timpul tastării răspunsului, acestea dovedindu-se esențiale pentru dezvoltarea proiectului prezentat. Au fost înregistrate: timpul propriu-zis de tastare al cuvântului, lungimea, pauza înregistrată după tastare, ora exactă la începutul și la finalul scrierii, dacă cuvântul a fost șters sau nu, numărul de litere șterse și toate versiunile prin care cuvântul a trecut până la finalizarea tastării.

Setul de date a fost compus în formatul json, cu câte o intrare pentru fiecare pereche întrebare-

răspuns care conține o listă cu datele necesare pentru fiecare cuvânt. În total, sunt incluse 212 propoziții formate din 4961 de cuvinte.

3.1.2 Modelul BERT

La baza comparației procesului de cogniție între modele și oameni stă evaluarea metricii de surprisal generată de fiecare cuvânt, aceasta fiind comparată cu timpii de tastare pentru a simula diferențele dintre cele două tipuri de autori. Metrica de surprisal măsoară probabilitatea condiționată de apariție a unui cuvânt într-o anumită propoziție, condiționată de restul părților lexicale. Aceasta este calculată utilizând negativul transformării logaritmice a informației probabilistice a cuvântului, deci cu cât este mai mare, acel cuvânt este cu atât mai improbabil să apară în propoziție. Din acest motiv a fost formulată ideea din această primă parte a tezei, și anume că ar trebui să existe o corelație semnificativă între surprisal-ul unui cuvânt și timpul acestuia de tastare, dacă construcția de propoziții este realizată în același mod de oameni respectiv de modele.

Calculul acestui surprisal se realizează cu ajutorul modelelor autoregresive, însă o estimare foarte bună a acestuia se poate realiza folosind probabilitățile logaritmice generate de un model bidirecțional. În cazul proiectului prezentat în această teză, s-a utilizat modelul lingvistic BERT, introdus în 2018[10], pentru a genera o astfel de estimare. BERT are capabilitatea de a returna probabilitățile transformate logaritmic pentru fiecare token dintr-o propoziție. Returnarea surprisal-ului pentru un anumit cuvânt din frază se va realiza prin ascunderea acestuia cu o tehnică de masking, extragrea probabilităților pentru acel token ascuns și căutarea probabilității corespunzătoare pentru cuvântul original.

3.1.3 Tehnici de masking

Întrucât obținerea unui rezultat cât mai relevant pentru scorul de surprisal este esențială proiectului, modul în care cuvintele sunt mascate trebuie stabilit pe baza unei analize detaliate. Ideal, se dorește ca după mascarea cuvântului țintă în propoziție, embedding-ul generat de BERT să rămână cât mai aproape de original. Pentru realizarea acestei analize, vor fi calculate embedding-urile pentru fiecare cuvânt dintr-un set de propoziții, iar acestea vor fi comparate cu

cele generate de ascunderea aceluiași cuvânt prin mai multe metode. La final, metoda care alterează cât mai puțin valorile obținute pentru propoziția originală, nemascată va fi utilizată pentru calcularea scorului de surprisal pe token-ul ascuns.

Dimensiunea setului de date original de 212 propoziții depășește cu mult nevoile acestei analize. Din acest motiv au fost generate 20 de propoziții suplimentare care să conțină o varietate de tipuri de cuvinte. Acestea sunt redactate în limba engleză, sunt mai scurte la doar 10-20 de cuvinte și au o structură similară cu răspunsurile din primul dataset. Se regăsesc în acest grup de propoziții cuvinte lungi, scurte, compuse cu sau fără cratimă, diverse părți de vorbire și construcții uzuale pentru a verifica cât mai detaliat impactul pe care tokenii suplimentari îl au asupra frazelor.

Prima metodă presupune utilizarea unui singur token de mascare, denumit „MASKED" în cod, care va înlocui cuvântul țintă în propoziție. Această metodă are ca avantaj utilizarea unui singur token suplimentar, reducând posibilitatea ca acesta să intervină în generarea embedding-urilor din restul propoziției. Dezavantajul acestei tehnici este însă evident atunci când cuvântul țintă este compus din mai mulți tokeni, întrucât calcularea probabilității logaritmice va fi realizată doar pentru prima parte a acestuia.

A doua metodă constă în înfășurarea cuvântului cu doi tokeni speciali de mascare, denumiți „START_WORD" și „END_WORD", care vor indica modelului BERT în ce zonă din propoziție să calculeze scorul de surprisal. Punctul forte al tehnicii cu doi tokeni este acoperirea cuvântului țintă în întregime, extinzând zona pentru care BERT calculează și la tokenii de după primul. O posibilă slăbiciune a acestei abordări ar putea apărea din cauza utilizării a doi tokeni suplimentari în loc de unul singur, fapt ce ar avea un impact disproporționat asupra embedding-ului pentru restul propoziției.

Utilizând aceste două metode și cele 20 de propoziții date ca exemplu s-au calculat două tipuri de similarități pentru a compara impactul metodelor de mascare. Prima similaritate este calculată între embedding-urile propoziției întregi originale și cele ale propoziției generate cu tehnica de mascare aleasă. A doua similaritate se uită doar la embedding-urile cuvintelor nemascate din propoziție, adică exclude cuvântul țintă atât în propoziția originală cât și în cea mascată. Tokenii speciali sunt excluși din embedding în ambele cazuri, întrucât sunt constante

pentru fiecare propoziție și ar introduce zgomot irelevant pentru scopul analizei.

Cuvinte mascate	Întreaga propoziție	Excluzând cuvântul țintă
Toate cuvintele	0.846	0.861
Cuvinte compuse	0.853	0.928
Cuvinte simple	0.845	0.854
Cuvinte scurte	0.97	0.976
Cuvinte lungi	0.672	0.7

Tabela 3.1: Mascarea cu 1 token - afectează similar tokenii din interiorul și din exteriorul zonei mascate

Cuvinte mascate	Întreaga propoziție	Excluzând cuvântul țintă
Toate cuvintele	0.743	0.655
Cuvinte compuse	0.805	0.736
Cuvinte simple	0.738	0.648
Cuvinte scurte	0.84	0.733
Cuvinte lungi	0.607	0.545

Tabela 3.2: Mascarea cu 2 tokeni - are rezultate foarte slabe, mai ales pe cuvinte lungi compuse din mai mulți tokeni

Se observă că prima metodă, cea din tabela 3.1, este mult mai performantă decât cea de a doua, pe toate tipurile de cuvinte. Prima metodă afectează embedding-ul pentru cuvântul țintă puțin mai profund decât pentru celelalte cuvinte din propoziție, în timp ce cea de-a doua are un impact mai mare în afara zonei mascate. De asemenea, similaritatea scade invers proporțional cu lungimea cuvântului, deci cu cât apar mai mulți tokeni în zona mascată, cu atât mai mult are de suferit toată propoziția.

Din tabela 3.2 se observă că utilizarea metodei a doua de mascare schimbă embedding-ul propoziției în mod drastic atunci când zona ascunsă este compusă din mai mulți tokeni. Acest lucru este datorat faptului că elementele de mascare („START_WORD” și „END_WORD” în acest caz) sunt separate între ele, deci afectează fiecare o zonă diferită din propoziție.

3.1.4 Calcularea scorului de surprisal prin BERT

Computarea propriu-zisă a metricii de surprisal depinde în mare parte de toate aspectele prezentate până acum. Cantitatea de intrări în dataset este corelată direct cu acuratețea datelor obținute, iar tipul de propoziții prezente în acesta va influența domeniul în care sunt evaluate aceste metrici. Metoda de mascare cu un singur token va furniza embedding-uri foarte similare

cu cele ale propoziției originale, însă va ascunde context important prezent în tokenii din coada cuvântului țintă. Inclusiv alegerea LLM-ului poate altera rezultatele, depinzând de tokenizer-ul și modelul utilizat.

Primul pas din acest proces este accesarea și preprocesarea setului de date, stocat într-un format „.csv". Datasetul conține intrări separate pentru fiecare pereche întrebare-răspuns, plus o listă denumită „word_metrics" care conține date despre fiecare cuvânt în parte. Cuvintele nule sau șterse sunt eliminate, iar restul sunt încărcate într-o listă pentru a putea fi procesate la pașii următori.

Al doilea pas constă în împărțirea propozițiilor în cuvinte utilizând o librărie de procesare a limbii naturale. Pentru acest proiect s-a folosit librăria spaCy [11], datorită eficienței la rulare și a rezultatelor bune. În ciuda faptului că setul de date oferă acces la cuvinte deja separate, acest pas suplimentar este necesar pentru a sparge cuvintele compuse în mai mulți tokeni, formă mai potrivită pentru BERT. Sincronizarea celor două liste de cuvinte se realizează prin spargerea cuvintelor compuse din setul de date în bucăți de lungimi corespunzătoare cu cele generate de spaCy, și ajustarea timpilor de tastare conform noilor lungimi. Spre exemplu, dacă un cuvânt compus de 10 litere avea durata de două secunde, o componentă de 5 litere ar avea durata nouă de o secundă. Întrucât doar primul token este mascat, nu va fi nevoie decât de separarea primului subtoken al cuvintelor compuse.

Odată ce a fost extras primul subtoken al fiecărui cuvânt, calculul metricii de surprisal poate începe. Se trimite către modelul BERT o propoziție generată prin combinarea întrebării cu răspunsul în care este mascat cuvântul țintă. Pe lângă acestea se trimite și primul subtoken pentru care va fi calculată valoarea de surprisal, în locul în care apărea tokenul suplimentar „MASKED". Rezultatul este mai apoi adăugat într-o listă în care sunt reținute mai multe informații despre fiecare cuvânt. Lista aceasta este, mai apoi, scrisă în fișierul „results.csv" care conține, pe lângă altele, timpii de scriere și scorul de surprisal pentru fiecare cuvânt din setul de date.

Întrucât procedeul de calcul al scorurilor de surprisal este costisitor, a fost introdus în program un sistem de fire de execuție. Fiecare fir de execuție primește referințe către model, tokenizer, propoziția mascată și date despre cuvântul țintă și are scopul de a returna valoarea generată de BERT. Sincronizarea tuturor firelor de execuție se realizează prin utilizarea unei liste inde-

xate, întrucât ordinea cuvintelor din fișierul rezultat trebuie să fie aceeași cu cea din datasetul primit.

3.1.5 Extragerea caracteristicilor pentru predictor

Următorul pas în dezvoltarea programului a constat în preprocesarea setului de date pentru antrenarea modelului de prezicere a timpilor de tastare. La baza acestui proces a stat extragerea, augmentarea și filtrarea feature-urilor pentru fiecare cuvânt aflat în propozițiile din dataset. Prezența unui număr mare și a unei varietăți semnificative de caracteristici garantează o acuratețe mai bună a modelului final, mai ales în cazul proiectului acesta, unde setul de date nu a avut o dimensiune considerabilă. Această etapă a necesitat două operații distincte dar legate în mod direct, și anume extragerea atributelor și, mai apoi, alegerea celor mai relevante și performante dintre ele.

Principalul obiectiv al pasului de selectare și augmentare a caracteristicilor este maximizarea varietății și cantității acestora, cu analiza utilității pentru model reprezentând o prioritate secundară. În cadrul setului de date original sunt prezente câteva atribute care vor fi preluate în acest pas, precum numărul de backspace-uri sau lungimea cuvântului. Unele caracteristici precum durata pauzei nu vor fi preluate, ele fiind strâns legate de valoarea țintă care va fi calculată de model, timpul de tastare. Inițial, la începutul proiectului, și scorul de surprisal a fost inclus în caracteristicile preluate la acest pas, însă corelația mică cu timpii de tastare a determinat excluderea metricii din antrenarea modelului.

Pe lângă puținele feature-uri prezente în setul de date inițial, la acest pas au mai fost generate și calculate alte caracteristici pentru a asigura o diversitate de opțiuni la antrenarea modelului. Cele mai simple dintre ele includ analiza lungimii cuvântului (două atribute booleene, dacă cuvântul este mai mic de 4 litere sau mai mare de 8), prezența unor semne de punctuație (precum virgule, cratime sau puncte), raportul de vocale/consoane sau poziția cuvântului în propoziție. Pe lângă acestea a fost calculată și frecvența cuvântului în limba engleză, utilizând librăria wordfreq[12], întrucât aceasta a prezentat o corelație însemnată cu timpii de tastare la pasul anterior.

Alte feature-uri au fost generate cu ajutorul listei de versiuni ale fiecărui cuvânt furnizate de setul de date original. Pe lângă numărul propriu-zis de versiuni, preluat din dataset, s-a

mai calculat și distanța levenshtein între prima variantă și cea finală a cuvântului, pentru a se cuantifica profunzimea schimbărilor realizate. Cu ajutorul listei de versiuni se poate face și o reconstrucție a procesului de tastare, care este utilizată pentru a calcula distanța parcursă de degete pe tastatură în timpul redactării. Întrucât modul în care sunt tastate cuvintele cu două mâini variază drastic de la o persoană la alta, calculul distanței pe tastatură a fost gândit pentru tipărirea cuvântului cu o singură mână, fapt ce cu siguranță va avea un efect negativ asupra acurateții acestei metrici.

Nu în ultimul rând, prin măsurarea interacțiunii dintre caracteristicile prezentate în paragrafele de până acum pot fi generate câteva alte feature-uri mai utile. Măsurarea corelației dintre distanța pe tastatură și numărul de backspace-uri tastate corectează o inacurateţe în calculul primei valori, întrucât prezența uneia, respectiv a mai multor taste backspace consecutive ar fi generat exact aceeași distanță. Regularizarea distanței Levenshtein sau a frecvenței cuvântului prin împărțirea la numărul de litere generează două caracteristici noi utile întrucât evită „pedepsirea" cuvintelor mai lungi în feature-urile originale. Întrucât calculul distanței de editare se uită doar la prima versiune a cuvântului, introducerea unui feature de interacțiune între acesta și numărul de versiuni poate genera o altă caracteristică utilă.

Deoarece numărul caracteristicilor generate de pasul anterior este deja suficient de mare, va trebui aplicat un pas de filtrare a feature-urilor pentru a putea dezvolta un model performant și robust. O modalitate bună de realizare a unei sortări după perfomanță a atributelor este antrenarea și analiza rezultatelor unui model restrâns. Pentru această etapă a fost utilizată librăria python scikit-learn[13], de unde au fost utilizate un model de tip Random Forest Regressor, GroupKFold pentru partiționarea datasetului în funcție de propozițiile din care fac parte cuvintele și metrica de permutation importance. Aceasta din urmă compară impactul pe care îl are fiecare caracteristică asupra acurateții modelului final, metrică ce va furniza o listă sortată cu cele mai importante feature-uri.

Pasul de sortare începe prin preluarea tuturor caracteristicilor generate de pasul anterior pe fiecare cuvânt, din fișierul word_features.csv. Apoi, se realizează o filtrare inițială pentru a ignora toate valorile legate în mod direct de timpul de tastare, acesta fiind setat ca target pentru model. Apoi datasetul este grupat pe propoziții și împărțit în 5 fold-uri care vor fi, pe rând, date

de antrenare respectiv testare. Porțiunea de antrenare este furnizată modelului Random Forest care mai apoi generează predicții pentru timpii de tastare pentru datele de testare. Acuratețea acestor predicții este cuantificată folosind metrica MAE (Mean Absolute Error) și apoi evaluată pentru fiecare feature prin permutation importance. La final, toate caracteristicile selectate sunt sortate după importanță, cuantificând impactul fiecăreia asupra antrenării modelului, iar cele mai bune sunt selectate pentru pasul următor, cel de antrenare.

3.1.6 Antrenarea modelelor de prezicere

Etapa de alegere, implementare și antrenare a modelului de prezicere reprezintă piesa centrală a întreg proiectului, fiind zona unde se pot realiza cele mai multe îmbunătățiri asupra produsului final. Selectarea unui tip de model potrivit pentru sarcina de prezicere a timpilor de tastare și pentru specificațiile setului de date pus la dispoziție este absolut necesară pentru obținerea unor rezultate decente. În cazul acestui proiect, nu va fi nevoie de cel mai complex model sau cel mai minuțios proces de antrenare, din cauza numărului redus de intrări în dataset, însă câteva îmbunătățiri specifice vor fi implementate pe rând.

Prima variantă de model a fost bazată pe un Gradient Boosting Regressor, implementat cu ajutorul modulului scikit-learn, mai exact varianta optimizată cu ajutorul histogramei. Principalul motiv pentru această alegere în defavoarea altor modele simpliste, precum Random Forest, a fost afinitatea GBR-urilor pentru feature-uri interactive, seturi de date tabulare și relații nonlineare între caracteristici. Această variantă a modelului a fost relativ simplă, cu doar maxim 300 de iterații ale procesului de boosting, o rată de învățare accelerată de 0,05, adâncime maximă a arborilor de 6 noduri și minim 10 sample-uri pentru fiecare nod split. Antrenarea a fost realizată pe exact același proces de folding ca cel utilizat la sortarea atributelor, cu setul de date partiționat în 5 grupuri distincte de propoziții. Rezultatele inițiale au fost bune, însă modelul atingea un plafon de performanță relativ repede.

Din cauza plafonării primului model, următorul pas a fost îmbunătățirea parametrilor acestuia: rata de învățare a fost scăzută la 0,02, iterațiile maxime au fost crescute la 1000, adâncimea a fost crescută la 10, numărul minim de sample-uri a fost scăzut la 5 și a fost introdusă o regularizare l2 pentru a reduce overfitting-ul. Performanța modelului a crescut în urma acestor

îmbunătățiri, însă același plafon a fost atins pe ultimele fold-uri, ceea ce a determinat decizia de a trece la un model mai performant pentru antrenare.

Modelul mai performant ales a fost LightGBM [14], bazat pe structuri arborescente și „gradient boosting", un mod de operare similar cu Gradient Boosting Regressor. Învățarea acestui model este bazată tot pe histograme, iar acesta oferă multe opțiuni utile pentru antrenarea rapidă și eficientă, precum mecanisme de early stopping sau paralelizarea procesului de training.

Versiunea implementată în program a fost, la început, una conservatoare, preferându-se un LightGBM cu mulți arbori slabi (2000 de trees cu rata de învățare 0,01 și 31 de frunze), și utilizarea subsample și colsample_bytree pentru a evita overfitting-ul. Această iterație a modelului nu a generat rezultate satisfăcătoare, declanșând mecanismul de early stopping al modelului și furnizând un scor MAE inferior modelului GBR. S-a decis mărirea complexității modelului, la 5000 de arbori cu 127 de frunze și adâncime 12, însă îmbunătățirea a fost minimă. Problema modelului LightGBM pare să fie legată de setul de date redus și numărul limitat de caracteristici utilizate. Deoarece nici mărirea numărului de feature-uri utilizate de model nu a adus un scor MAE apropiat de cel generat de GBR, s-a decis la revenirea modelului inițial cu parametrii mai performanți și câteva îmbunătățiri suplimentare.

Prima dintre aceste îmbunătățiri a fost introducerea transformării logaritmice a caracteristicii țintă: timpul de tastare. Din cauza unor intrări în setul de date cu valori extreme, scorul RMSE generat de model era departe de cel MAE, sugerând erori disproporționat de mari de prezicere pe câteva cuvinte. Pentru a combate pedepsirea modelului din cauza acestor valori extreme, a fost implementat target clipping prin transformarea logaritmică a caracteristicilor țintă, fapt ce a echilibrat raportul RMSE/MAE și a determinat o acuratețe crescută în evaluarea modelului.

A doua măsură introdusă pentru creșterea performanței modelului a fost adăugarea caracteristicilor interactive prezentate în subcapitolul anterior. Creșterea numărului de valori utilizate de la 5 la 9 principale plus 8 secundare a determinat rezultate mai bune pe toate tipurile de modele utilizate. Cele 17 atribute selectate au fost determinate după procesul de sortare bazat pe permutation importance, toate acestea având un efect pozitiv asupra modelului. Modelul final ales este un Hist. Gradient Boosting Regressor cu rata de învățare de 0,03, maxim 5000 de iterații, adâncime 14, limita de 20 de sample-uri, regulzarizare l2 și mecanism de early stopping.

3.1.7 Analiza performanței modelelor

Analiza performanței diferitelor modele a fost esențială pentru determinarea celui mai potrivit dintre ele, iar acest proces a fost realizat prin utilizarea mai multor scoruri din modulul sklearn.metrics. Primul astfel de scor a fost MAE, mean absolute error, o metrică care măsoară magnitudinea medie a erorilor dintr-un anumit sample. Pe lângă acest scor a mai fost utilizat și RMSE, root mean square error, care măsoară deviația standard a diferenței dintre predicții și ținte. Acest scor este util deoarece pedepsește disproporționat valorile extreme, oferind un alt punct de vedere asupra acurateții rezultatelor față de MAE. Cele două valori au fost calculate și afișate pentru fiecare fold, iar la finalul execuției au fost prezentate media și deviația standard măsurate pe toate bucățile setului de date.

Model	MAE	RMSE	Eroare totală (msec)
GBR slab	0.7355	1.8538	4171.5182
GBR puternic	0.6864	1.7259	4042.2957
LightGBM slab	0.7362	1.8585	4184.0178
LightGBM puternic	0.8056	1.915	4519.5836

Tabela 3.3: Performanța modelelor pe ultimul fold - scorurile obținute de Gradient Boosting Regressor sunt cele mai bune

Pentru comparația modelelor au fost prezentate scorurile obținute pe ultimul fold deoarece valoarea medie totală a scorurilor MAE și RMSE a fost similară pe toate cele 4 modele, în jur de 0.84 respectiv 2.81. Rezultatul obținut pe ultimul fold reprezintă performanța modelului în cel mai matur stagiu al antrenării, deci reflectă în mod direct eficacitatea acestuia la prezicere.

Ultima coloană din tabela 3.3 care descrie eroarea cumulativă în milisecunde pe toate cuvintele prezise dezvăluie detalii importante despre modelele antrenate. Se observă că acestea produc rezultate apropiate, fapt cauzat de plafonarea rapidă a acurateții în timpul procesului de învățare. Modelul LightGBM puternic înregistrează cel mai slab scor în această metrică, iar cele două bazate pe Gradient Boosting Regressor produc cea mai mică eroare.

Modelele bazate pe LightGBM prezintă un scor MAE mai mare pe exemplele test din cauza overfitting-ului major întâmpinat în procesul de antrenare, acestea având însă scoruri de sub 0.1 pe exemplele de training. Modelul GBR puternic a obținut cele mai bune scoruri, înregistrând valori constante ale acurateții și performând acceptabil și pe cazurile improbabile, fapt reflectat în scorul RMSE.

3.1.8 Interfața web

Comunicarea dintre utilizator și model necesită implementarea unei interfețe robuste, prin care transmiterea de date să fie cât mai rapidă și facilă. Din acest motiv s-a decis implementarea unei interfețe web în Django pentru acest proiect, framework potrivit pentru limbajul python în care este scris modelul. Scopurile principale ale modelului sunt înregistrarea datelor despre răspunsul tastat de utilizator, transmiterea acestora către modelul de prezicere și, mai apoi, comunicarea rezultatelor finale. În acest subcapitol vor fi detaliate toate trei operațiunile. Pentru a înregistra viteza de tastare a utilizatorului, este necesară o întrebare sau un subiect de discuție. Setul de date inițial oferă peste 200 de astfel de întrebări, din care se va alege aleator una și va fi comunicată utilizatorului. Sub întrebare este afișată o zonă în care se poate tasta răspunsul, loc în care sunt monitorizate versiunile cuvintelor și numărul de caractere backspace. Pentru acest proces este reținut un buffer pentru cuvântul curent care este salvat în lista de versiuni de fiecare dată când utilizatorul șterge o literă. La acționarea tastei space cuvântul final este înregistrat ca ultima variantă din lista de versiuni și salvat într-o listă separată cu cuvinte finale. Pe parcursul acestui proces este reținut și numărul de backspace-uri, iar acțiunea se finalizează când utilizatorul apasă tasta enter, moment în care timpul de tastare este salvat. Datele înregistrate sunt transmise înapoi într-un format json, care conține întrebarea originală, răspunsul final, timpul de tastare și o listă cu datele colectate pentru fiecare cuvânt.

Pentru a putea utiliza modelul creat anterior, acesta va trebui salvat și, mai apoi, reîncărcat în cadrul aplicației web. Aceste două operațiuni se vor realiza cu ajutorul bibliotecii joblib[15], modelul fiind salvat împreună cu lista de caracteristici utilizate într-un pachet de formatul .pkl. Pachetul este mai apoi deschis în cadrul aplicației web, unde mai apoi sunt transmise și datele adunate de la utilizator. Pentru aceste cuvinte sunt calculate toate atributele necesare, urmând ca toate acestea să fie încărcate în model. Acesta furnizează timpi atât pe întreaga propoziție cât și pentru fiecare cuvânt în parte. Pe lângă timpul propriu zis pe cuvânt se transmite mai departe și procentul din tot timpul propoziției și o valoare ajustată la ritmul de tastare al utilizatorului (folosind o scalare cu ajutorul timpului prezis și al celui real).

Toate valorile calculate de model sunt transmise într-un format json la frontend, unde vor fi afișate în interfață. Utilizatorul are acces la timpul real de tastare, cel estimat, ritmul său

de tastare și numărul de cuvinte utilizate. Mai jos sunt afișate și date despre fiecare cuvânt individual, împreună cu o opțiune de a le converti la viteza de tastare înregistrată.

3.2 Rezultate

3.2.1 Comparația surprisal cu timpii de tastare

Au fost generate cu ajutorul modelului BERT valorile de surprisal pentru fiecare cuvânt din setul de date, utilizând prima tehnică de mascare. În tabelul de mai jos sunt analizate corelațiile între aceste scoruri, timpii de tastare, timpii ajustați folosind pauzele de dinaintea cuvintelor, lungimea cuvântului și frecvența acestuia în limba engleză, toate luate două câte două.

Corelații	Timpi de tastare	Timpi ajustați	Lungime	Surprisal	Frecvență
Timpi de tastare	N/A	N/A	0.28	-0.17	-0.15
Timpi ajustați	N/A	N/A	0.23	-0.14	-0.12
Lungime	0.28	0.23	N/A	-0.45	-0.48
Surprisal	-0.17	-0.14	-0.45	N/A	0.32
Frecvență	-0.15	-0.12	-0.48	0.32	N/A

Tabela 3.4: Corelații între cele 5 valori - surprisal și timpii de tastare prezintă o legătură foarte slabă

Se observă imediat din tabela 3.4 o corelație neglijabilă între cele două valori centrale acestei analize: nu există o legătură pozitivă puternică între metrica de surprisal și timpii de tastare umani. Acest lucru sugerează existența unor diferențe însemnate între modul uman de construcție propozițională și cel al modelelor, acestea utilizând mai des cuvinte pe care subiecții umani nu le gândesc atât de rapid. Această concluzie este motivată și de alte observații din cadrul acestui domeniu, cum ar fi diferențele evidente dintre texte scrise de oameni, respectiv de inteligență artificială.

Pe lângă această observație, se pot deduce mai multe informații utile din tabelul prezentat. Lungimea unui cuvânt are un efect direct asupra timpilor de tastare, însă unul indirect asupra scorului de surprisal, demonstrând că modelele de limbaj natural nu au vreun bias puternic împotriva părților lexicale mai complexe. Frecvența utilizării în limbă se comportă exact invers, cuvintele mai frecvente ducând la timpi de tastare mai scurți însă la un surprisal mai mare. O posibilă explicație pentru această corelație ar putea fi dorința dezvoltatorilor modelului BERT

de a îi diversifica limbajul utilizat, acesta prioritizând cuvintele puțin mai obscure.

3.2.2 Importanța caracteristicilor

În urma generării caracteristicilor s-a dorit aplicarea unei sortări bazată pe contribuția la antrenarea modelului de prezicere. Rezultatele acestei analize sunt prezentate în schema de mai jos.

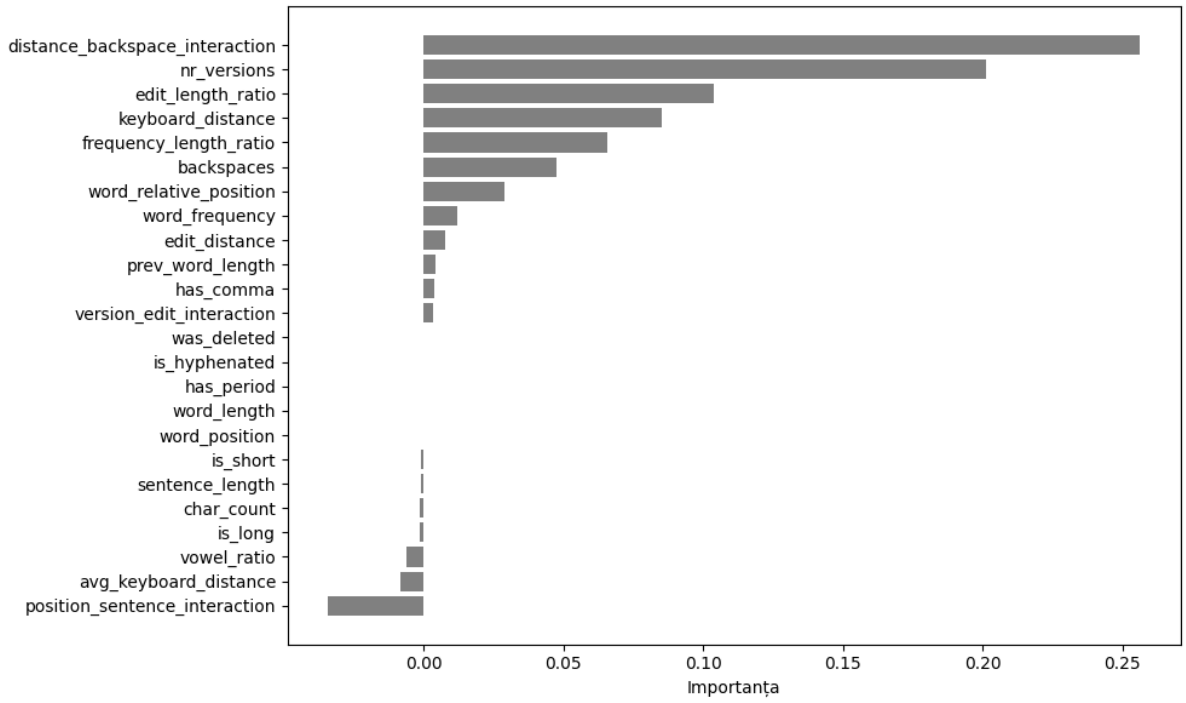


Figura 3.1: Sortarea bazată pe importanță a caracteristicilor - doar primele 9 feature-uri prezintă o importanță considerabilă

Din figura 3.1 se observă că cele mai performante atribute sunt legate de procesul de ștergere și rescriere a cuvântului tastat. Evident, acest proces este foarte costisitor și nu este reflectat în valori mai simple precum lungimea sau frecvența în vocabular. Distanța pe tastatură este, de asemenea, un predictor performant pentru timpii de scriere, deși nu simulează tastarea cu două mâini. Cele mai performante 9 feature-uri au fost selectate drept caracteristici primare, iar celelalte 8 care au totuși un impact pozitiv, de la lungimea cuvântului anterior până la poziția cuvântului actual, au fost selectate ca feature-uri secundare, folosite pentru modele care necesită mai multe date.

Capitolul 4

Concluzii

Dezvoltarea acestui proiect a prezentat diverse provocări și concluzii neașteptate pe parcursul întregului proces de creație. Ipotezele formulate la începutul acestuia au fost, în unele cazuri, modificate sau chiar răsturnate complet de datele obținute în urma analizei subiectului detaliat. Comparația dintre timpii de tastare și metrica de surprisal a demonstrat existența unor diferențe masive între producțiile lexicale umane și cele artificiale, subliniând faptul că modul de construcție propozițională al LLM-urilor nu este încă similar cu cel al oamenilor. Procesarea caracteristicilor pentru cuvintele din setul de date a confirmat câteva din intuițiile formulate, demonstrând ce detalii determină viteza de tastare a oamenilor. Alegerea modelului potrivit pentru setul de date utilizat a prezentat avantajele și dezavantajele modelelor mai complexe sau mai simple, demonstrând particularitățile domeniului de Machine Learning.

Concluzionând, redactarea acestei teze a prezentat un nou mod de a privi domeniul procesării limbajului natural, dezvoltând analiza unor particularități ale limbii umane care pot fi folosite pentru a augmenta experiența utilizatorilor modelelor de tip LLM.

Bibliografie

[1] Claire Doquet Georgeta Cislaru și Thierry Olive, „Introduction to the Special Issue | Operating units in written language performance: Linguistic and behavioral perspectives", în *Journal of Writing Research* 16.3 (2025), accesat: 2026-06-09, pp. 359–375, DOI: 10.17239/jowr-2025.16.03.01, URL: https://www.jowr.org/jowr/article/view/1719.

[2] Rui Alves, Teresa Limpo, Raquel Fidalgo, Lénia Carvalhais, Luísa Pereira și São Castro, „The Impact of Promoting Transcription on Early Text Production: Effects on Bursts and Pauses, Levels of Written Language, and Writing Performance", în *Journal of Educational Psychology* 108 (2015), accesat: 2026-06-13, pp. 665–679, DOI: 10.1037/edu0000089, URL: https://www.researchgate.net/publication/284514152_The_Impact_of_Promoting_Transcription_on_Early_Text_Production_Effects_on_Bursts_and_Pauses_Levels_of_Written_Language_and_Writing_Performance.

[3] Mark Torrance, Luuk Van Waes și David Galbraith, „Writing and cognition: Research and applications", în *Writing and Cognition: Research and Applications* (2007), accesat: 2026-06-13, pp. 1–377, DOI: 10.1163/9781849508223, URL: https://www.researchgate.net/publication/289870420_Writing_and_cognition_Research_and_applications.

[4] Pragati și Shubhajit Roy Chowdhury, „Keystroke-Based Cognitive Load Detection: A Large-Scale Analysis Across Age-Specific Cohorts", în *INDIAHCI* (2025), accesat: 2026-06-13, pp. 16–25, DOI: 10.1145/3768633.3770137, URL: https://dl.acm.org/doi/10.1145/3768633.3770137.

[5] Eva Lindgren și Kirk Sullivan, *Observing Writing: Insights from Keystroke Logging and Handwriting*, accesat: 2026-06-14, Brill, 2019, ISBN: 978-90-04-39252-6, DOI: 10.1163/9789004392526, URL: https://scispace.com/pdf/observing-writing-insights-from-keystroke-logging-and-2du2ddmbau.pdf.

[6] Sophie Slaats și Andrea E Martin, „What's Surprising About Surprisal", în *Computational Brain & Behavior* 8.1 (2025), accesat: 2026-06-09, pp. 233–248, DOI: 10.1007/s42113-025-00237-9, URL: https://link.springer.com/article/10.1007/s42113-025-00237-9.

[7] Ethan G. Wilcox, Tiago Pimentel, Clara Meister, Ryan Cotterell și Roger P. Levy, „Testing the Predictions of Surprisal Theory in 11 Languages", în *Transactions of the Association for Computational Linguistics* 11 (2023), accesat: 2026-06-14, pp. 1451–1470, DOI: 10.1162/tacl_a_00612, URL: https://direct.mit.edu/tacl/article/doi/10.1162/tacl_a_00612/118718/Testing-the-Predictions-of-Surprisal-Theory-in-11.

[8] Torrance M Wengelin A și Holmqvist K, „Combined eyetracking and keystroke-logging methods for studying cognitive processes in text production", în *Behav Res Methods* 41.2 (2009), accesat: 2026-06-13, pp. 337–351, DOI: 10.3758/BRM.41.2.337, URL: https://link.springer.com/article/10.3758/BRM.41.2.337.

[9] LLMxCon, *typing_data*, accesat: 2026-06-09, 2025, URL: https://github.com/Senthy30/LLMxCon/blob/main/typing_data/merged.json.

[10] Kenton Lee Jacob Devlin Ming-Wei Chang și Kristina Toutanova, „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding", în *Computation and Language* (2019), accesat: 2026-06-12, pp. 4171–4186, DOI: 10.48550/arXiv.1810.04805, URL: https://arxiv.org/abs/1810.04805.

[11] Explosion AI, *spaCy: Industrial-Strength Natural Language Processing in Python*, versiunea 3.7.4, accesat: 2026-06-09, 2025, URL: https://spacy.io.

[12] Robyn Speer, *wordfreq*, versiunea 3.1.1, accesat: 2026-06-09, 2025, URL: https://github.com/rspeer/wordfreq.

[13] scikit-learn developers, *scikit-learn: Machine Learning in Python*, versiunea 1.6.1, accesat: 2026-06-09, 2025, URL: https://scikit-learn.org.

[14] Microsoft Corporation, *LightGBM*, versiunea 4.6.0, accesat: 2026-06-09, 2025, URL: https://lightgbm.readthedocs.io.

[15] Joblib developers, *Joblib: Running Python Functions as Pipeline Jobs*, versiunea 1.5.3, accesat: 2026-06-09, 2025, URL: https://joblib.readthedocs.io.